

# Identificação de Sistema Linear por Erro de Predição

Guilherme de Paoli Beal

Universidade Federal do Rio Grande do Sul

**Resumo**—Aqui vai o resumo.

**Palavras-chave**—Identificação, Sistema Linear

## I. INTRODUÇÃO

As implementações são desenvolvidas em Python, versão 3.9.12. A identificação por erro de predição utiliza o pacote `pysid` em versão de desenvolvimento 0.1.0. O código deste projeto está publicado em [github.com/GuiBeal/system-identification](https://github.com/GuiBeal/system-identification).

## II. IDENTIFICAÇÃO POR ERRO DE PREDIÇÃO

Considere um sistema discreto, linear, invariante no tempo, com uma única entrada e uma única saída. A resposta deste sistema é dada por

$$y(t) = G_0(z) u(t) + \nu(t), \quad t \in \mathbb{N}, \quad (1)$$

em que  $y(t)$  é o sinal de saída,  $G_0(z)$  é a função de transferência do sistema,  $u(t)$  é o sinal de entrada,  $\nu(t)$  é um ruído de medição desconhecido,  $z$  é o operador de avanço — de modo que  $z x(t) = x(t+1)$  — e  $t \in \mathbb{N}$  é a variável de tempo discreto.

### A. Modelos

O modelo busca representar o sistema real  $G_0(q)$  expresso em (1). Em particular, na identificação por erro de predição, o modelo procurar caracterizar também o ruído  $\nu(t)$ .

Quatro diferentes classes de modelo são exploradas neste trabalho:

- Autorregressivo com Entrada Externa, ou *Autoregressive with Extra Input* (ARX);
- Autorregressivo com Média Móvel e Entrada Externa, ou *Autoregressive Moving Average with Extra Input* (ARMAX);
- Erro na Saída, ou *Output Error* (OE); e
- Box-Jenkins (BJ).

Essas classes são casos particulares de um modelo mais genérico, definido por

$$A(q) y(t) = \frac{B(q)}{F(q)} u(t) + \frac{C(q)}{D(q)} e(t), \quad (2)$$

em que  $e(t)$  é ruído branco. Os polinômios têm os formatos

$$\begin{aligned} A(q) &= 1 + a_1 q^{-1} + \dots + a_{n_a} q^{-n_a}, \\ B(q) &= q^{-n_k} (b_0 + b_1 q^{-1} + \dots + b_{n_b} q^{-n_b}), \\ C(q) &= 1 + c_1 q^{-1} + \dots + c_{n_c} q^{-n_c}, \\ D(q) &= 1 + d_1 q^{-1} + \dots + d_{n_d} q^{-n_d}, \text{ e} \\ F(q) &= 1 + f_1 q^{-1} + \dots + f_{n_f} q^{-n_f}, \end{aligned}$$

em que  $n_a, n_b, n_c, n_d$  e  $n_f$  são as ordens dos polinômios e  $n_k$  é o número de atrasos da entrada para a saída. Definindo as funções de transferência

$$\begin{aligned} G(q) &= \frac{B(q)}{A(q) F(q)}, \text{ e} \\ H(q) &= \frac{C(q)}{A(q) D(q)}, \end{aligned}$$

então (2) pode ser reescrita como

$$y(t) = G(q) u(t) + H(q) e(t).$$

Note que  $G(q)$  caracteriza o sistema real  $G_0(q)$ . Por sua vez, o ruído de medição  $\nu(t)$  é representado como ruído branco  $e(t)$  filtrado por  $H(q)$ :

$$\nu(t) = H(q) e(t).$$

Pelas definições dos polinômios,

$$H(\infty) = 1. \quad (3)$$

Outrossim, se o modelo representa um sistema amostrado, então  $G(q)$  deve ser estritamente própria — isto é, o grau de seu denominador é maior que o de seu numerador — o que é garantido com  $n_k \geq 1$ .

Ressalta-se que este modelo genérico pode apresentar definições e notações diferentes, como em [1]–[3]. A definição aqui apresentada corresponde aos formatos dos polinômios retornados pelas funções do pacote `pysid`.

### B. Predição

A predição é realizada aplicando

$$\hat{y}(t) = L_u(q) u(t) + L_y(q) y(t) \quad (4)$$

com

$$\begin{aligned} L_u(q) &= \frac{G(q)}{H(q)}, \text{ e} \\ L_y(q) &= 1 - \frac{1}{H(q)}. \end{aligned}$$

Embora isso não seja diretamente evidenciado por (4), o fato de  $G(q)$  ser estritamente própria juntamente com (3) garante que a predição  $\hat{y}(t)$  no instante  $t = t_0$  depende somente de valores de  $u(t)$  e  $y(t)$  em instantes  $t < t_0$  — isto é, a predição é realizado a partir de valores anteriores dos sinais de entrada e saída medidos.

O erro de predição é definido como

$$\varepsilon(t) = y(t) - \hat{y}(t) = \frac{y(t) - G(q)u(t)}{H(q)}.$$

Assim, o erro quadrático médio de predição é definido por

$$J = \frac{1}{N} \sum_{t=1}^N (\varepsilon(t))^2. \quad (5)$$

### C. Identificação

A identificação por erro de predição visa, a partir de um conjunto de dados de entrada  $u(t)$  e de saída  $y(t)$  medidos do processo, a identificar os parâmetros dos polinômios do modelo de forma a minimizar o custo expresso em (5). O algoritmo aplicado neste processo depende da classe do modelo e está fora do escopo deste trabalho. Estes são implementados pelo pacote `pysid`.

### D. Classes de Modelos

1) *ARX*: No modelo ARX há liberdade nas escolhas de  $n_a$ ,  $n_b$  e  $n_k$ , enquanto  $n_c = n_d = n_f = 0$ . Assim, as funções de transferência tornam-se

$$G(q) = \frac{B(q)}{A(q)}, \text{ e}$$

$$H(q) = \frac{1}{A(q)}.$$

Esta classe tem a vantagem de resultar numa minimização linear nos parâmetros, os quais podem ser obtidos por mínimos quadrados.

2) *ARMAX*: O modelo ARMAX requer a arbitração das ordens  $n_a$ ,  $n_b$ ,  $n_c$  e  $n_k$ , com  $n_d = n_f = 0$ . Portanto, as funções de transferência são

$$G(q) = \frac{B(q)}{A(q)}, \text{ e}$$

$$H(q) = \frac{C(q)}{A(q)}.$$

3) *Output Error*: Para o modelo OE são escolhidas as ordens  $n_b$ ,  $n_f$  e  $n_k$ , fixando  $n_a = n_c = n_d = 0$ . Nesse caso, tem-se

$$G(q) = \frac{B(q)}{F(q)}, \text{ e}$$

$$H(q) = 1.$$

Note que este modelo considera que o ruído de medição é ruído branco.

4) *Box-Jenkins*: Finalmente, no modelo BJ arbitra-se  $n_b$ ,  $n_c$ ,  $n_d$ ,  $n_f$  e  $n_k$ , com  $n_a = 0$ . Com isso, obtém-se

$$G(q) = \frac{B(q)}{F(q)}, \text{ e}$$

$$H(q) = \frac{C(q)}{F(q)}.$$

## III. DADOS

Os dados são apresentados na Figura 1, em que o sinal  $u(t)$  é multiplicado por um fator de 10 para melhor visualização. Ambos os sinais  $u(t)$  e  $y(t)$  contêm 200 amostras.




Figura 1. Dados de entrada e saída.

## IV. RESULTADOS

Tabela I  
MODELOS ARX MELHOR CLASSIFICADOS.

#	$n_a$	$n_b$	$n_k$

## V. CONCLUSÕES

### REFERÊNCIAS

- [1] L. Ljung, *Sytem identification: theory for the user*, 2nd ed. Upper Saddle River, NJ, Estados Unidos da América: Prentice Hall PTR, 1999.
- [2] L. A. Aguirre, *Introdução à identificação de sistemas: técnicas lineares e não-lineares aplicadas a sistemas reais*, 3rd ed. Belo Horizonte, MG, Brasil: Editora UFMG, 2007.
- [3] The MathWorks, Inc., “What are polynomial models?” Natick, MA, Estados Unidos da América, 2022. [Online]. Disponível em: <https://www.mathworks.com/help/ident/ug/what-are-polynomial-models.html>