

Identificação de Sistema por Erro de Predição com Modelos Racionais

Guilherme de Paoli Beal
Universidade Federal do Rio Grande do Sul
Programa de Pós-Graduação em Engenharia Elétrica
Aprendizado Supervisionado de Modelos Paramétricos

Resumo—Este trabalho busca identificar um sistema por erro de predição, a partir de um conjunto de dados de entrada e saída, com a saída corrompida por ruído de medição. As classes de modelo ARX, ARMAX, Output Error e Box-Jenkins, com diferentes ordens, são avaliadas. As identificações são realizadas pelo pacote `pysid` em linguagem Python. Os resultados são comparados pelo erro quadrático médio de predição e pelo critério de informação de Akaike ajustado para dados com poucas amostras.

Palavras-chave—Identificação por Erro de Predição, `pysid`, ARX, ARMAX, Output Error, Box-Jenkins

I. INTRODUÇÃO

Este trabalho visa à aplicação de identificação de um sistema discreto, linear e invariante no tempo, através do método de erro de predição, ou *Prediction Error Method* (PEM). Uma batelada de dados de um sistema, supostamente desconhecido, é fornecida, em que a saída está contaminada por ruído de medição. A identificação é realizada utilizando diferentes classes de modelo e ordens e os resultados são comparados.

As implementações são desenvolvidas em Python, versão 3.9.12. A identificação por erro de predição utiliza o pacote `pysid` em versão de desenvolvimento 0.1.0. O código deste projeto está publicado em github.com/GuiBeal/system-identification.

II. IDENTIFICAÇÃO POR ERRO DE PREDIÇÃO

Considere um sistema discreto, linear, invariante no tempo, com uma única entrada e uma única saída. A resposta deste sistema é dada por

$$y(t) = G_0(q) u(t) + \nu(t), t \in \mathbb{N}, \quad (1)$$

em que $y(t)$ é o sinal de saída, $G_0(q)$ é a função de transferência do sistema, $u(t)$ é o sinal de entrada, $\nu(t)$ é um ruído de medição desconhecido, q é o operador de avanço — de modo que $qx(t) = x(t+1)$ — e $t \in \mathbb{N}$ é a variável de tempo discreto. O ruído de medição é gerado a partir de ruído branco filtrado, como

$$\nu(t) = H_0(q) e(t),$$

em que $H_0(q)$ é a função de transferência do filtro e $e(t)$ é ruído branco.

G. Beal, guilherme.beal@ufrgs.br

A. Modelos Racionais

O modelo busca representar o sistema real $G_0(q)$ expresso em (1). Em particular, na identificação por erro de predição, o modelo procurar caracterizar também o ruído $\nu(t)$ através da identificação de $H_0(q)$.

Quatro diferentes classes de modelo racionais são exploradas neste trabalho:

- Autorregressivo com Entrada Externa, ou *Autoregressive with Extra Input* (ARX);
- Autorregressivo com Média Móvel e Entrada Externa, ou *Autoregressive Moving Average with Extra Input* (ARMAX);
- Erro na Saída, ou *Output Error* (OE); e
- Box-Jenkins (BJ).

Essas classes são casos particulares de um modelo mais genérico, definido por

$$A(q) y(t) = \frac{B(q)}{F(q)} u(t) + \frac{C(q)}{D(q)} e(t). \quad (2)$$

Os polinômios têm os formatos

$$\begin{aligned} A(q) &= 1 + a_1 q^{-1} + \dots + a_{n_a} q^{-n_a}, \\ B(q) &= q^{-n_k} (b_0 + b_1 q^{-1} + \dots + b_{n_b} q^{-n_b}), \\ C(q) &= 1 + c_1 q^{-1} + \dots + c_{n_c} q^{-n_c}, \\ D(q) &= 1 + d_1 q^{-1} + \dots + d_{n_d} q^{-n_d}, \text{ e} \\ F(q) &= 1 + f_1 q^{-1} + \dots + f_{n_f} q^{-n_f}, \end{aligned}$$

em que n_a, n_b, n_c, n_d e n_f são suas ordens e n_k é o número de atrasos da entrada para a saída. Definindo as funções de transferência

$$\begin{aligned} G(q) &= \frac{B(q)}{A(q) F(q)}, \text{ e} \\ H(q) &= \frac{C(q)}{A(q) D(q)}, \end{aligned}$$

então (2) pode ser reescrita como

$$y(t) = G(q) u(t) + H(q) e(t).$$

Note que $G(q)$ visa a caracterizar o sistema real $G_0(q)$. Por sua vez, o ruído de medição $\nu(t)$ é representado como ruído branco $e(t)$ filtrado por $H(q)$.

Pelas definições dos polinômios,

$$H(\infty) = 1. \quad (3)$$

Outrossim, se o modelo representa um sistema amostrado, então $G(q)$ deve ser estritamente própria — isto é, o grau

de seu denominador é maior que o de seu numerador — o que é garantido com $n_k \geq 1$.

Ressalta-se que este modelo genérico pode apresentar definições e notações diferentes, como em [1]–[3]. A definição aqui apresentada corresponde ao formato dos polinômios retornados pelas funções do pacote `pysid`.

B. Predição

A predição é realizada aplicando

$$\hat{y}(t) = L_u(q) u(t) + L_y(q) y(t) \quad (4)$$

com

$$L_u(q) = \frac{G(q)}{H(q)}, \text{ e}$$

$$L_y(q) = 1 - \frac{1}{H(q)}.$$

Embora isso não seja diretamente evidenciado por (4), o fato de $G(q)$ ser estritamente própria juntamente com (3) garante que a predição $\hat{y}(t)$ no instante $t = t_0$ depende somente de valores de $u(t)$ e $y(t)$ em instantes $t < t_0$ — isto é, a predição é realizado a partir de valores anteriores dos sinais de entrada e saída medidos.

O erro de predição é definido como

$$\varepsilon(t) = y(t) - \hat{y}(t) = \frac{y(t) - G(q) u(t)}{H(q)}.$$

Assim, o erro quadrático médio de predição é definido por

$$J = \frac{1}{N} \sum_{t=1}^N (\varepsilon(t))^2, \quad (5)$$

em que N é o número de amostras preditas.

C. Identificação

A identificação por erro de predição visa, a partir de um conjunto de dados de entrada $u(t)$ e de saída $y(t)$ medidos do processo, a identificar os parâmetros dos polinômios do modelo de forma a minimizar o custo expresso em (5). O algoritmo aplicado neste processo depende da classe do modelo e está fora do escopo deste trabalho. Estes são implementados pelo pacote `pysid`.

D. Classes de Modelos

As quatro classes de modelo são obtidas fixando determinadas ordens no modelo genérico.

1) *ARX*: Neste modelo, há liberdade nas escolhas de n_a , n_b e n_k , enquanto $n_c = n_d = n_f = 0$. Assim, as funções de transferência tornam-se

$$G(q) = \frac{B(q)}{A(q)}, \text{ e}$$

$$H(q) = \frac{1}{A(q)}.$$

Esta classe tem a vantagem de fazer com que (5) seja quadrática nos parâmetros, os quais podem, portanto, ser calculados por mínimos quadrados.

2) *ARMAX*: Este modelo requer a arbitração das ordens n_a , n_b , n_c e n_k , com $n_d = n_f = 0$. Portanto, as funções de transferência são

$$G(q) = \frac{B(q)}{A(q)}, \text{ e}$$

$$H(q) = \frac{C(q)}{A(q)}.$$

3) *Output Error*: Para este modelo são escolhidas as ordens n_b , n_f e n_k , fixando $n_a = n_c = n_d = 0$. Nesse caso, tem-se

$$G(q) = \frac{B(q)}{F(q)}, \text{ e}$$

$$H(q) = 1.$$

Note que este modelo considera que o ruído de medição é ruído branco.

4) *Box-Jenkins*: Finalmente, neste modelo arbitra-se n_b , n_c , n_d , n_f e n_k , com $n_a = 0$. Com isso, obtém-se

$$G(q) = \frac{B(q)}{F(q)}, \text{ e}$$

$$H(q) = \frac{C(q)}{D(q)}.$$

III. CRITÉRIO DE INFORMAÇÃO DE AKAIKE

Para avaliar a qualidade dos modelos identificados será utilizado o critério de informação de Akaike, ou *Akaike Information Criterion* (AIC). Este critério pondera a qualidade de predição junto à ordem do modelo, penalizando critérios de maior ordem. Considerando o erro de predição, o critério é definido por

$$\text{AIC} = N \log(J) + 2k,$$

em que N é o número de amostras preditas, k é o número de parâmetros do modelo e J é o erro médio quadrático de predição definido em (5) [4].

Para conjuntos com poucas amostras, pode-se utilizar um critério adaptado, definido por

$$\text{AICc} = \text{AIC} + \frac{2k(k+1)}{N-k-1}. \quad (6)$$

Note que $N \rightarrow \infty \implies \text{AICc} \rightarrow \text{AIC}$ — isto é, o critério adaptado se aproxima do critério original à medida que cresce o número de amostras considerado.

IV. DADOS

Os dados são apresentados na Figura 1, em que o sinal $u(t)$ é multiplicado por um fator de 10 para melhor visualização. Ambos os sinais $u(t)$ e $y(t)$ contêm 200 amostras. Note que a entrada $u(t)$ é similar a uma onda quadrada.

Na Figura 1, a linha tracejada vertical divide os dados em dois conjuntos. Para a identificação dos modelos, utilizam-se os dados à esquerda desta linha, correspondentes às primeiras 160 amostras. As 40 amostras restantes são aplicadas na validação dos modelos identificados.

A Figura 2 mostra o espectro de amplitude dos dados — isto é, a magnitude da transformada de Fourier dos sinais — em escala logarítmica. Note como ambos os sinais possuem um conteúdo elevado em baixas frequências, seguidos de picos pontuais que decrescem com o aumento da frequência.




Figura 1. Dados de entrada e saída.




Figura 2. Espectro de amplitude dos dados de entrada e saída.

V. RESULTADOS

Diversas identificações são realizadas, variando as ordens dos polinômios e o atraso entre as quatro classes de modelos. A Tabela I sintetiza os intervalos de variação desses valores para cada modelo. A fim de considerar sistemas amostrados, todos os sistemas tem atraso de pelo menos um amostra — isto é, $n_k \geq 1$.

Tabela I
INTERVALO DE VARIAÇÃO DAS ORDENS DOS POLINÔMIOS

| Classe | n_a | n_b | n_c | n_d | n_f | n_k | Total |
|--------|--------|--------|--------|--------|--------|--------|-------|
| ARX | [1, 4] | [0, 4] | — | — | — | [1, 4] | 80 |
| ARMAX | [1, 4] | [0, 4] | [1, 4] | — | — | [1, 4] | 320 |
| OE | — | [0, 4] | — | — | [1, 4] | [1, 4] | 80 |
| BJ | — | [0, 4] | [0, 4] | [1, 4] | [1, 4] | [1, 4] | 1600 |
| Total | | | | | | | 2080 |

Destaca-se que dentre as 1600 identificações realizadas com a classe BJ 960 apresentaram algum problema de implementação interno ao pacote `pysid`. Nesses casos, os modelos foram descartados. Assim, o total de modelos efetivamente identificados é de 1120.

Para cada identificação são calculados o erro quadrático médio, conforme (5), e o critério de informação de Akaike para pequenos conjuntos de dados, conforme (6). Ambos são realizados tanto para o conjunto de dados de identificação — denotado pelo subíndice i — como para o conjunto de validação — denotado pelo subíndice v .

Para cada uma das quatro classes, a Tabela II apresenta os seis melhores modelos resultantes, com base no critério

de informação de Akaike com os dados de validação — isto é, $AICc_v$. Os modelos são unicamente identificados por um índice, exibidos na primeira coluna.

Comparando a ordem de grandeza de cada critério de qualidade na Tabela II, nota-se que os modelos ARX, ARMAX e BJ apresentam um desempenho consideravelmente melhor que os modelos OE; isto é um indicativo de que o ruído de medição não é branco, conforme supõe esse último modelo. Além disso, para os modelos ARX, ARMAX e BJ, todos as identificações presentes na Tabela II têm $n_k = 1$ — isto é, um atraso da entrada para a saída de apenas uma amostra. Destaca-se, ainda, que entre os modelos ARMAX e BJ presentes na Tabela II todas as identificações têm n_c partindo de seu valor mínimo — 1 para ARMAX e 0 para BJ —, levando à interpretação de que o numerador de $H(q)$ tem ordem pequena.

A Tabela III mostra as 20 melhores identificações, novamente classificadas pelo critério de informação de Akaike adaptado com os dados de validação — $AICc_v$. Note a prevalência de modelos ARX, bem como das características discutidas no parágrafo anterior.

A partir das identificações, são obtidas as funções de transferência do sistema $G(q)$ e do ruído $H(q)$. A fim de compará-las visualmente, as Figuras 3 e 4 apresentam suas respostas em frequência, considerando as identificações na Tabela III.




Figura 3. Respostas em frequência de $G(q)$ a partir das identificações na Tabela III.

Note, através da Figura 3, que, entre todas as identificações, o comportamento do sistema $G(q)$ é semelhante nas baixas frequências mas discordante nas altas frequências. Isso está em consonância com o fato de que os dados trazem mais informações nas baixas frequências, conforme visto na Figura 2. Por outro lado, a Figura 4 mostra que o sistema $H(q)$ é mais diverso entre as diferentes identificações.

As predições das identificações presentes na Tabela III são exibidas na Figura 5. Os respectivos erros de predição — também denominados resíduos — são mostrados na Figura

Tabela II
MELHORES RESULTADOS POR CLASSE COM BASE NO CRITÉRIO AICC_v

| # | Classe | n_a | n_b | n_c | n_d | n_f | n_k | AICC _v | AICC _i | J_v | J_i |
|------|--------|-------|-------|-------|-------|-------|-------|-------------------|-------------------|---------|--------|
| 24 | ARX | 2 | 1 | – | – | – | 1 | 79,463 | 288,142 | 5,801 | 5,750 |
| 44 | ARX | 3 | 1 | – | – | – | 1 | 80,358 | 289,971 | 5,556 | 5,740 |
| 28 | ARX | 2 | 2 | – | – | – | 1 | 80,596 | 276,503 | 5,589 | 5,276 |
| 20 | ARX | 2 | 0 | – | – | – | 1 | 80,820 | 290,423 | 6,384 | 5,910 |
| 40 | ARX | 3 | 0 | – | – | – | 1 | 81,303 | 291,572 | 6,074 | 5,875 |
| 32 | ARX | 2 | 3 | – | – | – | 1 | 82,077 | 278,289 | 5,410 | 5,264 |
| 160 | ARMAX | 2 | 0 | 1 | – | – | 1 | 82,406 | 292,387 | 6,244 | 5,905 |
| 240 | ARMAX | 3 | 0 | 1 | – | – | 1 | 82,440 | 291,698 | 5,853 | 5,802 |
| 192 | ARMAX | 2 | 2 | 1 | – | – | 1 | 83,302 | 278,685 | 5,579 | 5,277 |
| 144 | ARMAX | 1 | 4 | 1 | – | – | 1 | 83,435 | 299,330 | 5,199 | 5,922 |
| 112 | ARMAX | 1 | 2 | 1 | – | – | 1 | 83,574 | 294,450 | 6,021 | 5,902 |
| 336 | ARMAX | 4 | 1 | 1 | – | – | 1 | 84,031 | 282,669 | 5,277 | 5,337 |
| 465 | OE | – | 4 | – | – | 1 | 2 | 203,538 | 635,576 | 112,710 | 49,103 |
| 469 | OE | – | 4 | – | – | 2 | 2 | 205,126 | 637,238 | 108,924 | 48,942 |
| 466 | OE | – | 4 | – | – | 1 | 3 | 208,209 | 688,227 | 126,671 | 68,237 |
| 468 | OE | – | 4 | – | – | 2 | 1 | 210,717 | 620,915 | 125,264 | 44,195 |
| 470 | OE | – | 4 | – | – | 2 | 3 | 211,195 | 690,408 | 126,771 | 68,234 |
| 464 | OE | – | 4 | – | – | 1 | 1 | 211,208 | 622,115 | 136,532 | 45,141 |
| 1136 | BJ | – | 2 | 0 | 2 | 1 | 1 | 82,909 | 276,778 | 5,524 | 5,214 |
| 816 | BJ | – | 1 | 0 | 2 | 1 | 1 | 83,040 | 273,646 | 5,941 | 5,183 |
| 832 | BJ | – | 1 | 0 | 3 | 1 | 1 | 84,041 | 276,120 | 5,683 | 5,193 |
| 1456 | BJ | – | 3 | 0 | 2 | 1 | 1 | 84,939 | 277,505 | 5,398 | 5,167 |
| 1140 | BJ | – | 2 | 0 | 2 | 2 | 1 | 85,844 | 278,965 | 5,521 | 5,214 |
| 848 | BJ | – | 1 | 0 | 4 | 1 | 1 | 86,957 | 274,874 | 5,677 | 5,083 |

Tabela III
MELHORES RESULTADOS GERAIS COM BASE NO CRITÉRIO AICC_v

| # | Classe | n_a | n_b | n_c | n_d | n_f | n_k | AICC _v | AICC _i | J_v | J_i |
|------|--------|-------|-------|-------|-------|-------|-------|-------------------|-------------------|-------|-------|
| 24 | ARX | 2 | 1 | – | – | – | 1 | 79,463 | 288,142 | 5,801 | 5,750 |
| 44 | ARX | 3 | 1 | – | – | – | 1 | 80,358 | 289,971 | 5,556 | 5,740 |
| 28 | ARX | 2 | 2 | – | – | – | 1 | 80,596 | 276,503 | 5,589 | 5,276 |
| 20 | ARX | 2 | 0 | – | – | – | 1 | 80,820 | 290,423 | 6,384 | 5,910 |
| 40 | ARX | 3 | 0 | – | – | – | 1 | 81,303 | 291,572 | 6,074 | 5,875 |
| 32 | ARX | 2 | 3 | – | – | – | 1 | 82,077 | 278,289 | 5,410 | 5,264 |
| 64 | ARX | 4 | 1 | – | – | – | 1 | 82,145 | 288,495 | 5,419 | 5,611 |
| 160 | ARMAX | 2 | 0 | 1 | – | – | 1 | 82,406 | 292,387 | 6,244 | 5,905 |
| 240 | ARMAX | 3 | 0 | 1 | – | – | 1 | 82,440 | 291,698 | 5,853 | 5,802 |
| 1136 | BJ | – | 2 | 0 | 2 | 1 | 1 | 82,909 | 276,778 | 5,524 | 5,214 |
| 816 | BJ | – | 1 | 0 | 2 | 1 | 1 | 83,040 | 273,646 | 5,941 | 5,183 |
| 36 | ARX | 2 | 4 | – | – | – | 1 | 83,283 | 281,484 | 5,179 | 5,297 |
| 192 | ARMAX | 2 | 2 | 1 | – | – | 1 | 83,302 | 278,685 | 5,579 | 5,277 |
| 60 | ARX | 4 | 0 | – | – | – | 1 | 83,403 | 291,217 | 5,995 | 5,784 |
| 144 | ARMAX | 1 | 4 | 1 | – | – | 1 | 83,435 | 299,330 | 5,199 | 5,922 |
| 112 | ARMAX | 1 | 2 | 1 | – | – | 1 | 83,574 | 294,450 | 6,021 | 5,902 |
| 48 | ARX | 3 | 2 | – | – | – | 1 | 83,698 | 278,625 | 5,634 | 5,275 |
| 336 | ARMAX | 4 | 1 | 1 | – | – | 1 | 84,031 | 282,669 | 5,277 | 5,337 |
| 832 | BJ | – | 1 | 0 | 3 | 1 | 1 | 84,041 | 276,120 | 5,683 | 5,193 |
| 52 | ARX | 3 | 3 | – | – | – | 1 | 84,774 | 280,442 | 5,376 | 5,263 |




Figura 4. Respostas em frequência de $H(q)$ a partir das identificações na Tabela III.

6. Observe que, de forma geral, as previsões das várias identificações são próximas entre si.

Finalmente, a Figura 7 exibe a autocorrelação dos resíduos. Caso um modelo fosse capaz de explicar plenamente a dinâmica do sistema, então os resíduos decorreriam apenas da aleatoriedade do ruído de medição e seriam semelhantes a ruído branco — o qual é descorrelacionado de si mesmo exceto para atraso nulo. A autocorrelação dos resíduos, porém, mostra um valor elevado para atraso nulo — conforme esperado — e valores diversos nos demais atrasos, mostrando que o resíduo não se aproxima de ruído branco.




Figura 5. Previsões a partir das identificações na Tabela III.




Figura 6. Resíduos de predição a partir das identificações na Tabela III.




Figura 7. Autocorrelação dos resíduos de predição a partir das identificações na Tabela III.

A. Escolha de Modelos Adequados

Através das observações anteriores, procura-se escolher classes e ordens de modelo razoáveis para representar o sistema efetivo, ainda desconhecido. Os modelos OE são logo descartados devido ao seu desempenho inferior. Ademais, o atraso é arbitrado como $n_k = 1$ pois esse valor prevalece nos modelos bem-classificados.

Conforme já citado, o numerador de $H(q)$ parece ser de ordem pequena. Em particular, com a prevalência de modelos BJ com $n_c = 0$ — o que equivale a $C(q) = 1$, sem parâmetros — e de modelos ARX, descarta-se também a classe ARMAX. Restam, portanto, modelos ARX e modelos BJ com $n_c = 0$. A diferença entre esses dois casos é que o primeiro requer que os denominadores de $G(q)$ e $H(q)$ sejam iguais, enquanto o segundo permite que sejam independentes.

Finalmente, por apresentar melhores classificações gerais com estrutura mais simples, sugere-se a utilização do modelo ARX. Pelos resultados, sugere-se uma ordem n_a entre 2 e 3. A ordem n_b pode ser arbitrada entre 0 e 3. Ressalta-se que a escolha de ordens mais elevadas permite contemplar uma quantidade maior de modelos na classe, ao custo de exigir a identificação de mais parâmetros. Conforme já mencionado, o atraso sugerido é $n_k = 1$.

B. Desempenho do Menor Modelo de Ordem Completa

As funções de transferência que efetivamente geraram os dados são agora reveladas como

$$G_0(q) = \frac{2q^2 + 2q - 1,5}{q^3 - 1,4q^2 + 0,48q} = \frac{q^{-1}(2 + 2q^{-1} - 1,5q^{-2})}{1 - 1,4q^{-1} + 0,48q^{-2}}, \text{ e}$$

$$H_0(q) = \frac{q^3}{q^3 - 1,4q^2 + 0,48q} = \frac{1}{1 - 1,4q^{-1} + 0,48q^{-2}}.$$

Observe que os denominadores de $G_0(q)$ e $H_0(q)$ são idênticos. Além disso, no formato de potências negativas, o numerador de $H_0(q)$ é unitário. Assim, a classe de modelo ARX com $n_a = 2$, $n_b = 2$ e $n_k = 1$ é a menor classe que contém o sistema efetivo.

Note, através das Tabelas II e III, que essa classe corresponde à identificação de índice 28. Além disso, é a terceira

melhor classificada tanto entre os modelos ARX como no geral. Seus polinômios são

$$A_{28}(q) = 1 - 1,40683 q^{-1} + 0,482612 q^{-2}, \text{ e}$$

$$B_{28}(q) = q^{-1} (2,16247 + 1,61084 q^{-1} - 1,60164 q^{-2}),$$

os quais resultam nas funções de transferência

$$G_{28}(q) = \frac{2,16247 q^2 + 1,61084 q - 1,60164}{q^3 - 1,40683 q^2 + 0,482612 q}$$

$$= \frac{q^{-1} (2,16247 + 1,61084 q^{-1} - 1,60164 q^{-2})}{1 - 1,40683 q^{-1} + 0,482612 q^{-2}}, \text{ e}$$

$$H_{28}(q) = \frac{q^3}{q^3 - 1,40683 q^2 + 0,482612 q}$$

$$= \frac{1}{1 - 1,40683 q^{-1} + 0,482612 q^{-2}}.$$

A Figura 8 mostra a previsão da saída a partir desta identificação, em comparação aos dados de validação. Conforme consta nas Tabelas II e III, o erro quadrático médio associado é 5,589.




Figura 8. Previsão obtida com o menor modelo de ordem completa.

A comparação com os sistemas efetivos é realizada pelas respostas em frequência das funções de transferência, as quais são exibidas nas Figuras 9 e 10. Observe que a função $G_{28}(q)$ apresenta um ganho estático visivelmente abaixo de $G_0(q)$.

VI. CONCLUSÕES

A determinação da classe do modelo é um desafio ao projetista, ainda mais quando a ordem do sistema a ser identificado é desconhecida. O erro quadrático médio de predição e o critério de informação de Akaike permitem avaliar a qualidade dos modelos obtidos.

Tendo sido realizada uma única identificação por classe, sempre a partir do mesmo conjunto de dados de identificação e validação, os resultados têm um fator considerável de aleatoriedade. A aleatoriedade poderia ser reduzida com a divisão do conjunto de dados em múltiplos subconjuntos de identificação e validação — procedimento este denominado validação cruzada — e posterior comparação dos vários resultados obtidos para cada classe.




Figura 9. Resposta em frequências de $G(q)$ a partir da identificação com o menor modelo de ordem completa.




Figura 10. Resposta em frequências de $H(q)$ a partir da identificação com o menor modelo de ordem completa.

REFERÊNCIAS

- [1] L. Ljung, *Sytem identification: theory for the user*, 2nd ed. Upper Saddle River, NJ, Estados Unidos da América: Prentice Hall PTR, 1999.
- [2] L. A. Aguirre, *Introdução à identificação de sistemas: técnicas lineares e não-lineares aplicadas a sistemas reais*, 3rd ed. Belo Horizonte, MG, Brasil: Editora UFMG, 2007.
- [3] The MathWorks, Inc., “What are polynomial models?” Natick, MA, Estados Unidos da América, 2022. [Online]. Disponível em: <https://www.mathworks.com/help/ident/ug/what-are-polynomial-models.html>
- [4] T. Söderström and P. Stoica, *System Identification*. Hemel Hempstead, Reino Unido: Prentice Hall, 1989.